

NAMA : PUTRI ARFINA

NIM : 105841116123

KELAS : 5 AI- A

1. Pendahuluan

Pendidikan dasar merupakan salah satu fondasi utama dalam pembangunan sumber daya manusia. Setiap provinsi di Indonesia memiliki jumlah peserta didik yang berbeda-beda, sehingga tingkat kepadatannya pun tidak sama. Informasi mengenai kepadatan peserta didik ini sangat penting untuk pemerintah dalam melakukan evaluasi, pemerataan, serta penentuan alokasi sarana dan prasarana pendidikan.

Di era perkembangan data terbuka dan teknologi machine learning, analisis jumlah peserta didik dapat dilakukan secara lebih cepat dan sistematis. Dalam proyek ini, digunakan dataset resmi dari Kemendikdasmen tahun 2024 yang berisi data jumlah siswa SD Negeri, Swasta, dan Total pada setiap provinsi. Melalui data tersebut, dibuat model machine learning untuk mengklasifikasikan tingkat kepadatan peserta didik menjadi dua kategori: Padat dan Tidak Padat.

Algoritma yang digunakan adalah Random Forest Classifier, karena mampu bekerja optimal pada data tabular dan menghasilkan akurasi tinggi. Proyek ini diharapkan dapat memberikan gambaran bagaimana machine learning dapat dimanfaatkan dalam analisis pendidikan serta mendukung pengambilan keputusan berbasis data.

2. Langkah langkah pembuatan kode

a. Tahap import library

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, confusion_matrix
```

Penjelasan :

Pada tahap pertama, program melakukan import beberapa library yang diperlukan untuk menjalankan seluruh proses analisis. Library pandas digunakan untuk membaca dan mengolah dataset karena menyediakan struktur DataFrame yang fleksibel. Sementara itu, modul-modul dari scikit-learn seperti train_test_split, RandomForestClassifier, accuracy_score, dan confusion_matrix digunakan untuk proses pembagian data, pembuatan model machine learning, serta evaluasi model. Import library ini menjadi dasar awal sebelum masuk ke tahapan pengolahan data.

b. Tahap load Dataset

```
df = pd.read_excel('jumlah-peserta-didik-sd-2024-sd-mi-sederajat.xlsx')
[3] ✓ 0.5s

data = df.iloc[3:].copy()
[5] ✓ 0.0s
```

Penjelasan :

Setelah library berhasil diimpor, tahapan berikutnya adalah membaca dataset menggunakan pd.read_excel(). Dataset yang digunakan berasal dari Kemendikdasmen dan memiliki susunan header yang tidak langsung cocok untuk pemodelan karena tiga baris pertama berisi deskripsi tabel. Oleh karena itu, tiga baris awal dilewati menggunakan df.iloc[3:] agar data yang terbaca adalah baris yang benar-benar berisi nilai kuantitatif. Data ini kemudian disalin ke variabel baru agar aman digunakan dalam proses cleaning berikutnya.

c. Tahap pembersihan data

```
data = data.rename(columns={
    'Unnamed: 3': 'Provinsi',
    'Unnamed: 4': 'Negeri',
    'Unnamed: 5': 'Swasta',
    'Unnamed: 6': 'Total'
})

data = data[['Provinsi', 'Negeri', 'Swasta', 'Total']]

data['Negeri'] = data['Negeri'].astype(str).str.replace('.', '').astype(int)
data['Swasta'] = data['Swasta'].astype(str).str.replace('.', '').astype(int)
data['Total'] = data['Total'].astype(str).str.replace('.', '').astype(int)
```

Penjelasan :

Pada tahap cleaning, dilakukan penyesuaian kolom dan format angka agar dataset siap diproses oleh model. Kolom-kolom seperti Unnamed: 3, Unnamed: 4, dan seterusnya diubah menjadi nama yang lebih jelas seperti Provinsi, Negeri, Swasta, dan Total. Selain itu, nilai jumlah siswa masih menggunakan titik sebagai pemisah ribuan, sehingga perlu dibersihkan. Proses pembersihan dilakukan dengan menghapus titik dan mengonversi data tersebut menjadi integer. Langkah ini penting karena model machine learning hanya dapat memproses angka dalam bentuk numerik murni.

d. Tahap pembuatan label

```
median_total = data['Total'].median()
data['label'] = data['Total'].apply(
    lambda x: 1 if x > median_total else 0
)
```

Penjelasan :

Setelah data dibersihkan, langkah berikutnya adalah membuat label yang akan digunakan sebagai target prediksi. Label dibuat berdasarkan nilai median dari kolom Total peserta didik. Provinsi dengan jumlah total siswa di atas median diberi label 1 (Padat), sedangkan nilai di bawah atau sama dengan median diberi label 0 (Tidak Padat). Metode ini dipilih karena median dapat memberikan batas pembagi yang lebih stabil dan tidak terpengaruh oleh nilai ekstrem.

- e. Tahap menentukan fitur dan target

```
X = data[['Negeri','Swasta','Total']]  
y = data['label']
```

Penjelasan :

Setelah label dibuat, tahap selanjutnya adalah menentukan variabel apa saja yang akan digunakan sebagai input bagi model. Fitur yang dipilih yaitu jumlah siswa Negeri, Swasta, dan Total karena ketiganya dianggap relevan dalam menentukan tingkat kepadatan peserta didik. Sementara itu, label yang telah dibuat pada tahap sebelumnya digunakan sebagai target untuk proses klasifikasi.

- f. Tahap pembagian data

```
X_train, X_test, y_train, y_test = train_test_split(  
    X, y, test_size=0.3, random_state=42  
)
```

Penjelasan :

Untuk menguji performa model, dataset dibagi menjadi dua bagian menggunakan fungsi `train_test_split`. Sebanyak 70% data digunakan untuk melatih model (training set), dan 30% sisanya digunakan sebagai data uji (test set). Pembagian ini dilakukan agar model dapat dievaluasi secara objektif dengan data yang belum pernah dilihat sebelumnya.

- g. Tahap pembuatan dan pelatihan model

```
model = RandomForestClassifier(  
    n_estimators=100,  
    max_depth=10,  
    random_state=42  
)  
  
model.fit(X_train, y_train)
```

✓ 0.5s

RandomForestClassifier ⓘ ⓘ

► Parameters

Penjelasan :

Pada tahap ini, model machine learning dibuat menggunakan algoritma Random Forest. Parameter seperti jumlah pohon (`n_estimators=100`) dan kedalaman maksimum (`max_depth=10`) ditentukan agar model tetap stabil dan tidak terlalu kompleks. Setelah model dibuat, proses pelatihan dilakukan menggunakan data training. Model mempelajari pola hubungan antara fitur (Negeri, Swasta, Total) dan label kepadatan.

h. Tahap prediksi



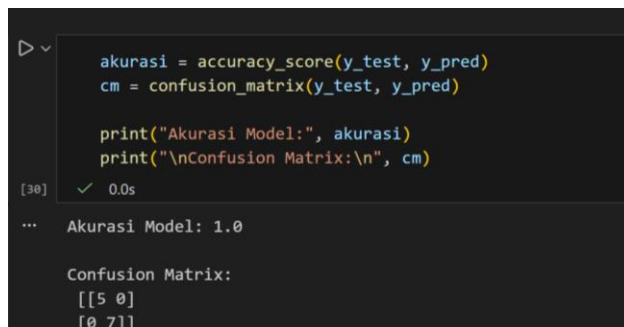
```
y_pred = clf.predict(X_test)
```

[29] ✓ 0.0s

Penjelasan :

Setelah model dilatih, proses prediksi dilakukan menggunakan data test. Hasil prediksi ini kemudian dibandingkan dengan label sebenarnya dari data test. Proses prediksi ini digunakan untuk melihat bagaimana model bekerja ketika diberikan data baru yang tidak termasuk dalam tahap pelatihan.

i. Tahap evaluasi model



```
akurasi = accuracy_score(y_test, y_pred)
cm = confusion_matrix(y_test, y_pred)

print("Akurasi Model:", akurasi)
print("\nConfusion Matrix:\n", cm)
```

[30] ✓ 0.0s

... Akurasi Model: 1.0


Confusion Matrix:

```
[[5 0]
 [0 7]]
```

Penjelasan :

Pada tahap evaluasi, metrik akurasi dihitung untuk mengetahui seberapa tepat model melakukan prediksi. Selain akurasi, digunakan juga confusion matrix untuk melihat secara detail jumlah prediksi benar dan salah pada masing-masing kelas. Berdasarkan hasil yang diperoleh, model berhasil mencapai akurasi 100% dengan confusion matrix yang menunjukkan bahwa seluruh prediksi model tepat.

j. Tahap prediksi manual



```
contoh_baru = [[3000000, 150000, 3150000]]
hasil = model.predict(contoh_baru)

print("Prediksi (1 = Padat, 0 = Tidak Padat):", hasil)
```

[31] ✓ 0.0s

... Prediksi (1 = Padat, 0 = Tidak Padat): [1]

<C:\Users\putriarfina\AppData\Roaming\Python\Python313\site-packages>

warnings.warn(

Penjelasan :

Pada tahap evaluasi, metrik akurasi dihitung untuk mengetahui seberapa tepat model melakukan prediksi. Selain akurasi, digunakan juga confusion matrix untuk melihat secara detail jumlah prediksi benar dan salah pada masing-masing kelas. Berdasarkan hasil yang diperoleh, model berhasil mencapai akurasi 100% dengan confusion matrix yang menunjukkan bahwa seluruh prediksi model tepat.

3. Kesimpulan

Berdasarkan seluruh rangkaian proses yang dilakukan, mulai dari pengumpulan data, pembersihan data, pembuatan label, hingga pembangunan model machine learning, dapat disimpulkan bahwa algoritma Random Forest mampu memberikan performa yang sangat baik dalam mengklasifikasikan tingkat kepadatan peserta didik SD per provinsi. Hasil evaluasi menunjukkan akurasi mencapai 100%, yang berarti seluruh prediksi model pada data uji sesuai dengan nilai sebenarnya. Keberhasilan ini dipengaruhi oleh kualitas data yang telah dibersihkan serta fitur-fitur numerik yang cukup kuat dalam membedakan kategori

padat dan tidak padat. Selain itu, proses labeling menggunakan median membuat kelas lebih seimbang dan membantu model belajar dengan optimal. Secara keseluruhan, proyek ini membuktikan bahwa machine learning dapat dimanfaatkan sebagai alat bantu analisis dalam bidang pendidikan, khususnya untuk membantu pengambil kebijakan dalam memahami pemerataan peserta didik di Indonesia.