

LEMBAR KERJA MAHASISWA (LKM)

LK.8 Perancangan Project Data Science

Nama	: PUTRI ARFINA
Tanggal	: 06/12/2025
Kelas	: AI – A
Judul Project	: Prediksi Kepadatan Peserta Didik SD Menggunakan Algoritma Random Forest

A. Instruksi

Peserta diminta untuk merancang sebuah proyek Data Science yang berfokus pada permasalahan di bidang pendidikan. Rancangan proyek ini harus disusun secara sistematis berdasarkan metodologi CRISP-DM (Cross Industry Standard Process for Data Mining) yang mencakup enam tahapan utama, yaitu:

1. Business Understanding (Pemahaman Bisnis)
2. Data Understanding (Pemahaman Data)
3. Data Preparation (Persiapan Data)
4. Modeling (Pemodelan)
5. Evaluation (Evaluasi)
6. Deployment (Penerapan)

Pada setiap tahapan, peserta diharapkan dapat:

1. Menjelaskan tujuan dan fokus kegiatan pada tahap tersebut.
2. Menguraikan langkah-langkah yang dilakukan serta teknik atau metode yang digunakan.
3. Menjelaskan jenis dan sumber data yang diperlukan.
4. Menunjukkan hasil atau keluaran yang diharapkan dari tiap tahap.

Gunakan contoh kasus nyata atau permasalahan aktual di dunia pendidikan, seperti: Prediksi prestasi belajar siswa, Analisis tingkat kehadiran, Deteksi dini siswa berisiko tidak lulus, atau Rekomendasi pembelajaran adaptif berbasis data.

Hasil akhir dari tugas ini berupa dokumen rancangan proyek Data Science lengkap yang menggambarkan alur proses dari awal hingga implementasi model, serta menunjukkan bagaimana solusi berbasis data dapat memberikan manfaat nyata bagi peningkatan mutu pendidikan.

B. Deskripsi singkat proyek

Proyek ini melakukan prediksi tingkat kepadatan peserta didik SD di seluruh provinsi di Indonesia menggunakan data jumlah siswa Negeri, Swasta, dan Total dari portal resmi Kemendikdasmen. Model yang digunakan adalah Random Forest Classifier dengan pendekatan CRISP-DM.

C. Format Perancangan

Tahapan CRISP-DM	Instruksi untuk Peserta	Rancangan Implementasi
1. Business Understanding (Pemahaman Bisnis)	- Pilih konteks pendidikan (contoh: sekolah, universitas, pelatihan). - Identifikasi permasalahan yang dapat diselesaikan dengan data science. - Rumuskan tujuan bisnis (contoh: meningkatkan prestasi siswa, menurunkan	Perbedaan jumlah peserta didik antar provinsi menyebabkan adanya ketimpangan kepadatan. Proyek ini bertujuan memprediksi kategori kepadatan (padat/tidak padat) berdasarkan data real Kemendikdasmen sebagai dasar analisis pemerataan pendidikan.

	tingkat ketidakhadiran).	
2. Data Understanding (Pemahaman Data)	- Jelaskan sumber data (contoh: data nilai siswa, absensi, data keluarga). - Sebutkan jenis data (numerik, kategorikal, teks, waktu). - Deskripsikan fitur dan target yang akan digunakan.	Dataset diambil dari Kemendikdasmen: <code>jumlah-peserta-didik-sd-2024-sd-mi-sederajat.xlsx</code> . Struktur kolom: Provinsi, Negeri, Swasta, Total. Data memiliki header bertingkat sehingga perlu melewati 3 baris awal. Ditemukan adanya format angka bertitik.
3. Data Preparation (Persiapan Data)	- Tuliskan langkah pembersihan data: hapus duplikat, tangani nilai kosong, dan outlier. - Transformasi data: normalisasi, encoding data kategorikal.	Langkah: 1) Menghapus titik pada angka; 2) Konversi integer; 3) Rename kolom; 4) Membuat label dengan median total siswa (1 = padat, 0 = tidak padat). Fitur: Negeri, Swasta, Total.
4. Modeling (Pemodelan)	- Pilih algoritma yang sesuai (contoh: Decision Tree, Random Forest, Logistic Regression). - Jelaskan alasan pemilihan algoritma.	Model: Random Forest. Parameter: <code>n_estimators=100</code> , <code>max_depth=10</code> , <code>random_state=42</code> . Dipilih karena akurat dan cocok untuk data tabular. Data dibagi train 70% dan test 30%.
5. Evaluation (Evaluasi)	Pilih metode evaluasi yang akan digunakan misalkan menggunakan cross-validation atau confusion matrix.	Evaluasi menggunakan akurasi dan confusion matrix. Hasil: Akurasi 100%. CM: <code>[[5,0],[0,7]]</code> . Tidak ada kesalahan prediksi.
6. Deployment (Penerapan / Implementasi)	Buat rancangan deploymentnya tampilan interface nya	Model digunakan melalui Jupyter Notebook. Input manual dapat dimasukkan untuk prediksi tanpa menggunakan Gradio.

D. Kesimpulan proyek

Model Random Forest menunjukkan performa sempurna pada dataset, menghasilkan akurasi 100%. Fitur jumlah siswa Negeri, Swasta, dan Total terbukti mampu mengklasifikasikan tingkat kepadatan peserta didik secara akurat.